



MACHINE LEARNING CLASIFICACIÓN Y REGRESIÓN



EXPLORACIÓN DE DATOS EN MACHINE LEARNING

Módulo 1

Unidad 2: Técnicas de validación de datos




Objetivo

El objetivo general del módulo es desarrollar una comprensión integral del rol de los datos y de la importancia de su adecuada preparación y tratamiento previo, como paso fundamental para el desarrollo de modelos de aprendizaje automático.

Unidad 2

- Generalización
- Split de datos.
- Validación cruzada.
- Sesgo y varianza.
- Detección de ruido.

Generalización






La **generalización** implica que un modelo es capaz de aprender **patrones** generales y aplicarlos a nuevos datos.

Un buen modelo debe predecir **correctamente** en **ejemplos desconocidos**.

El objetivo de entrenar modelos de ML es **maximizar** la **generalización**.

Split de datos




Split de datos

Para evaluar generalización, dividimos el dataset en:

Entrenamiento (train): para ajustar el modelo.

Prueba (test): para medir el rendimiento final en datos no vistos.



Split de datos

Un método común es usar `train_test_split` de scikit-learn.

```
X_train, X_test, y_train, y_test = train_test_split(X, y,  
                                                    test_size=0.2, random_state=42)
```


Esto hace una división aleatoria 80/20.

Para clasificación se suele añadir `stratify=y` para mantener la proporción de clases en train y test.


Para datos temporales, NO se deben mezclar aleatoriamente las muestras: si los datos están ordenados por tiempo, la división debe respetar el orden cronológico (o usar técnicas específicas para series temporales)

Split de datos

Validación (opcional): para seleccionar hiperparámetros o monitorizar.



Validación cruzada



Validación cruzada (cros validation)

Es una técnica que maximiza el uso de los datos para evaluar la generalización.

Se divide el dataset en K “pliegues” (folds) y se repite el entrenamiento K veces, cada vez reservando un pliegue diferente como conjunto de prueba.

El rendimiento final es el promedio de las métricas en cada iteración. Esto reduce la varianza de la estimación del error y suele aprovechar mejor los datos, especialmente si son pocos.


Validación cruzada (cros validation)

Cómo implementar en scikit-learn:

```
from sklearn.model_selection import  
cross_val_score, KFold
```


```
clf = LogisticRegression()
```

```
kf = KFold(n_splits=5,  
shuffle=True, random_state=42)  
scores = cross_val_score(clf, X, y,  
cv=kf, scoring='accuracy')
```



Otras técnicas: K-Fold estratificado, Leave-One-Out (LOO), TimeSeriesSplit, GroupKFold.

Sesgo y varianza



Underfitting (subajuste)

Ocurre cuando el modelo es demasiado simple para capturar el patrón real de los datos.

El modelo no aprende suficientemente durante el entrenamiento.

Características

- Malo en entrenamiento

- Malo en test

- El modelo no logra representar la relación entre variables.

Underfitting (subajuste)

Ocurre cuando el modelo es demasiado simple para capturar el patrón real de los datos.

El modelo no aprende suficientemente durante el entrenamiento.

Cómo solucionarlo

- Modelo más complejo.

- Agregar variables (features).

- Entrenar más tiempo.

- Usar algoritmos más potentes.

Overfitting (sobreajuste)

Ocurre cuando el modelo aprende demasiado bien los datos de entrenamiento, incluyendo ruido o casos particulares, y por eso no generaliza a nuevos datos.

El modelo memoriza en lugar de aprender patrones generales.

Características

Bueno en entrenamiento.

Malo en test.

Modelo demasiado complejo.

Overfitting (sobreajuste)

Ocurre cuando el modelo aprende demasiado bien los datos de entrenamiento, incluyendo ruido o casos particulares, y por eso no generaliza a nuevos datos.

El modelo memoriza en lugar de aprender patrones generales.

Cómo solucionarlo

- Más datos.

- Regularización.

- Reducir número de features.

- Simplificar el modelo.

- Usar validación cruzada.

Underfitting vs Overfitting



Sesgo

Mide qué tan lejos está, en promedio, lo que predice el modelo de la realidad, debido a las suposiciones que el modelo hace sobre los datos.

En otras palabras:

Aparece cuando el modelo simplifica demasiado el problema y por eso no puede representar correctamente el patrón real de los datos.

Mide cuánto se equivoca un modelo porque es demasiado simple para representar el problema.


Un modelo con alto sesgo (p.ej. regresión lineal simple ante una relación no lineal) tiende a subajustarse (underfitting).

Varianza


La varianza mide la sensibilidad del modelo a los datos de entrenamiento.

Un modelo con alta varianza (p.ej. un polinomio muy complejo) suele sobreajustarse (overfitting)

El truco en machine learning es encontrar un equilibrio entre bias y varianza.



Deteccción de ruido



Detección de ruido

El ruido en un dataset son datos irrelevantes o erróneos que dificultan el aprendizaje. Esto incluye:

Outliers/valores atípicos: Puntos muy desviados de la tendencia general. Pueden surgir por errores de medición o eventos raros

Ruido de etiquetas: Etiquetas (y) incorrectas o inconsistentes. Esto sesga al modelo: “las etiquetas incorrectas pueden sesgar el modelo y afectar su rendimiento

Valores faltantes: la muestra se puede ver condicionada a la presencia de valores faltantes o sin información.

Duplicados: dependerá del caso de uso si validación o eliminación.

Detección de ruido


¿Cómo podemos mitigarlo?

Outliers: se pueden eliminar o transformar.

Ruido de etiquetas, se suele depurar manualmente o con técnicas semiautomáticas.

En general, buena limpieza de datos y exploración (visualización) ayuda a identificar ruido.


Resumen



Resumen de la clase

- Qué es la generalización de un modelo y por qué es crucial en ML.
- Diseñar apropiadamente la división de un dataset.
- Implementar técnicas de validación cruzada.
- Distinguir entre sesgo / varianza y underfitting / overfitting.
- Detectar diferentes tipos de ruido en los datos.

¿Consultas?



¡Muchas gracias!

