



MACHINE LEARNING CLASIFICACIÓN Y REGRESIÓN



Métodos de validación de información

Módulo 2


Unidad 1: Metaclasificadores



Unidad 1

- Ensamble de modelos.
- Paralelo vs secuencial.
- Algoritmos más usados.

Metclasificadores (ensamble)





Un **ensamble (ensemble)** es una técnica de machine learning que consiste en **combinar múltiples modelos para producir una única predicción final**.

Idea simple: muchos modelos simples combinados pueden producir un modelo más robusto que uno solo.

Se basa en el principio de **sabiduría de la multitud (wisdom of the crowd)**: en lugar de confiar en un solo experto, juntamos un comité de varios expertos para tomar una decisión final más precisa y robusta.



Un **metaestimador o ensamble** será entonces un "modelo de modelos".

Su trabajo es combinar las predicciones de varios modelos más simples (llamados estimadores base) para lograr una predicción final mucho más precisa y robusta.

Ejemplo: queremos predecir si un cliente abandonará un servicio.

Modelo 1: Árbol 1

Predicción: **Abandona**

Modelo 2: Árbol 2

Predicción: **No abandona**


Modelo 3: Árbol 3

Predicción: **Abandona**

Predicción final (votación mayoritaria) → **Abandona**

¿Por qué funcionan los Ensambles?

Los modelos individuales cometen **errores distintos**. Al combinarlos, reducimos el riesgo de error y mejoramos el rendimiento general. Si un modelo se equivoca, es más probable que la predicción conjunta sea correcta.



Reducir Varianza

Disminuye la sensibilidad a fluctuaciones en los datos de entrenamiento



Reducir Sesgo


Corrige errores sistemáticos de modelos individuales



Mejorar Generalización

Aumenta la capacidad de predecir correctamente en datos nuevos

Tipos de ensambles




Tipos de ensambles

Ensamble Paralelo: los modelos se entrenan de forma independiente. Luego sus predicciones se combinan.


Ejemplos: Bagging, Random Forest.

Ensamble Secuencial: los modelos se entrenan uno después del otro. Cada nuevo modelo intenta corregir los errores del anterior.

Ejemplos: AdaBoost, Gradient Boosting, XGBoost, LightGBM.



Técnica de bootstrapping



Técnica de bootstrapping

El **bootstrapping** es una técnica estadística de muestreo con reemplazo que genera muchos datasets distintos a partir de uno solo.

01

Dataset Original

Partimos de un conjunto de datos original con N observaciones.

02

Muestreo con Reemplazo

Creamos un nuevo conjunto seleccionando N observaciones del original con reemplazo ("vuelve a la bolsa")

03

Repetición


Repetimos el proceso múltiples veces, generando conjuntos de datos con composición ligeramente distinta

Ejemplo: Dataset original: [1,2,3,4,5] → Muestra bootstrap: [2,3,3,5,1]

Observación: algunos datos se repiten, otros pueden no aparecer

Esta técnica permite entrenar muchos modelos distintos aunque tengamos un solo dataset. Al entrenar cada clasificador con conjuntos remuestreados, nos aseguramos de que cada modelo "vea" una versión diferente de la realidad, reduciendo la varianza y mejorando la generalización.

Ensembles paralelos (Bagging)



Bagging (Bootstrap Aggregating)

Combina dos ideas: Bootstrap (crear múltiples conjuntos de datos mediante muestreo con reemplazo) + agregación (entrenar un modelo completo en cada conjunto).

Como cada modelo:

- ve una versión ligeramente diferente de los datos,
- aprende patrones distintos y desarrolla sus propias fortalezas y debilidades.

Para la predicción final, se combinan los resultados: votación mayoritaria en clasificación, promedio en regresión.

Bagging (Bootstrap Aggregating)

Ejemplo: Precio de Viviendas

Modelo	Predicción
Árbol 1	210k
Árbol 2	220k
Árbol 3	215k

Predicción final (promedio): 215k

Ventajas


- Reduce varianza
- Mejora estabilidad
- Fácil de paralelizar

Desventajas


- Menos interpretable
- Requiere más recursos computacionales

Random Forest

Random Forest es una extensión del bagging aplicada a árboles de decisión que introduce más aleatoriedad. Además del bootstrapping, cada árbol usa **solo un subconjunto de variables en cada división**, haciendo que los árboles sean más diversos.



Ensembles secuenciales (Boosting)



AdaBoost (Adaptive Boosting)

Asigna pesos a las observaciones y aprende de forma secuencial, adaptando esos pesos en cada paso.

#

Primer Modelo

Se entrena un modelo simple que hace clasificaciones correctas e incorrectas

###

Identificación

Se identifican las muestras mal clasificadas

x

Ajuste de Pesos

Se da más importancia a las muestras difíciles

U

Nuevo Modelo

Se entrena prestando atención a muestras con mayor peso

↺

Repetición

El proceso se repite, cada modelo corrige errores anteriores

AdaBoost (Adaptive Boosting)

El proceso se asemeja a un estudiante que se prepara para un examen, enfocándose en los temas que le resultan más difíciles.

La predicción final se obtiene mediante votación ponderada de todos los modelos, donde los "expertos" más fiables tienen más peso en la decisión final.



Gradient Boosting


Gradient Boosting es una técnica de boosting conceptualmente más avanzada.

También construye modelos de forma secuencial, donde cada nuevo modelo corrige al anterior, pero lo hace con un enfoque matemáticamente más sofisticado.

En lugar de ajustar pesos como AdaBoost, se enfoca directamente en los **residuos** (errores entre predicción y valor real).

Cada nuevo modelo se construye para minimizar los errores del conjunto, utilizando descenso de gradiente para encontrar el punto óptimo.

Gradient Boosting



📱 Ejemplo: Predicción del Precio de una Vivienda

Predicción Inicial: Precio promedio del barrio: \$200,000

Cálculo de Errores: Casa de \$250,000 tiene error de +\$50,000. Casa de \$180,000 tiene error de -\$20,000

Primer Árbol: Aprende que "si tiene 4 habitaciones, error +\$50,000" y "si tiene 2 habitaciones, error -\$20,000"

Actualización: Casa de 4 habitaciones: $\$200,000 + \$50,000 = \$250,000$

Siguientes Pasos: Se repite corrigiendo errores más pequeños hasta lograr precisión

XGBoost y LightGBM

XGBoost

Extreme Gradient Boosting es una versión optimizada de Gradient Boosting que se volvió muy popular en competencias de ciencia de datos.

Mejoras Principales

- Regularización avanzada
- Paralelización eficiente
- Manejo optimizado de memoria
- Control robusto de overfitting


Muchos ganadores de **Kaggle** utilizan XGBoost.

LightGBM


Otra implementación eficiente de boosting con características distintivas.

Características

- Más rápido que XGBoost en datasets grandes
- Menor consumo de memoria
- Crecimiento de árbol más eficiente



Desempeño de modelos



Desempeño de modelos


Comparación: Paralelos vs. Secuenciales

Característica	Paralelos	Secuenciales
Ejemplos	Bagging, Random Forest	AdaBoost, Gradient Boosting
Entrenamiento	Independiente	Dependiente
Objetivo principal	Reducir varianza	Reducir sesgo
Paralelización	Fácil	Difícil
Velocidad	Más rápido	Más lento
Precisión	Alta	Muy alta

¿Cuándo podría no mejorar un ensamble?

- 1. Modelos con alto sesgo:** Si el modelo base es demasiado simple para capturar la complejidad del problema, promediar predicciones incorrectas resulta en un modelo final también incorrecto.
- 2. Datos con mucho ruido:** Si los datos contienen información irrelevante o etiquetas erróneas, los modelos pueden aprender ese ruido.


Resumen



Resumen de la clase

- Ensamble de modelos.
- Diferencias entre paralelo y secuencial.
- Algoritmos bagging y boosting.

¿Consultas?



¡Muchas gracias!

