



MACHINE LEARNING CLASIFICACIÓN Y REGRESIÓN



Aprendizaje supervisado

Módulo 3


Unidad 1: Entrenamiento de modelos




Unidad 1

- Entrenamiento y función de costo
- Regresión lineal simple
- Regresión lineal múltiple
- Regresión logística
- Métricas de clasificación y regresión

Entrenamiento supervisado





Entrenamiento de Modelos Supervisados

En aprendizaje supervisado tenemos variables de entrada (X) y variable objetivo (y).

El objetivo es aprender una función $f(X) \rightarrow y$ que permita predecir la variable objetivo a partir de las variables de entrada.

El entrenamiento consiste en:

- definir un modelo (algoritmo + datos),
- establecer una función de costo,
- encontrar los parámetros que minimizan el error.

¿Qué ocurre durante el Entrenamiento?

El modelo sigue un proceso iterativo y sistemático para mejorar sus predicciones.

01

Predicción Inicial

El modelo hace una predicción inicial, generalmente mala

02

Comparación

Compara esa predicción con el valor real

03

Cálculo de Error

Calcula un error usando la función de costo

04

Ajuste de Parámetros

Ajusta sus parámetros para reducir ese error

05

Repetición

Repite este proceso muchas veces

Funciones de Costo

También conocida como "**función de pérdida**" (**loss function**), es una medida matemática que cuantifica qué tan bien o mal está funcionando un modelo al comparar sus predicciones con los valores reales.

MSE (Mean Squared Error)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Penaliza errores grandes por el cuadrado. Mide la esperanza del error cuadrático. Si MSE = 0 → ajuste perfecto. Si MSE crece → peor ajuste. Es diferenciable → permite optimización.

Cross Entropy Loss


$$J = -\frac{1}{n} \sum [y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

Penaliza mucho cuando estás muy seguro y te equivocas. Mejor que MSE para clasificación.


Optimización de función de costo

Intuición de optimización: El algoritmo busca el mínimo de la función de costo. Imaginá una "superficie de error" donde el modelo "baja" por la pendiente hasta encontrar el mínimo.

Descenso del Gradiente (Gradient Descent): Es el algoritmo de optimización más común para minimizar la función de costo. ([link1](#), [link2](#))



Regresión lineal simple



Regresión Lineal Simple

El modelo más básico: $y = \beta_0 + \beta_1 x$, donde β_0 es el intercepto (valor de y cuando $x=0$) y β_1 es la pendiente (cambio esperado en y por unidad de x).

Modela la relación existente entre una variable Y y una variable independiente mediante el ajuste de una ecuación lineal.

Objetivo


Encontrar la recta que mejor se ajusta a los datos

Interpretación

Geométrica

Minimiza la suma de distancias verticales al cuadrado

Regresión Lineal Simple




Ejemplo


Predecir precio de casa según m^2

Limitaciones

- Solo captura relaciones lineales
- Sensible a outliers



Regresión lineal múltiple



Regresión lineal múltiple

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Extiende la regresión lineal simple para trabajar con múltiples variables de entrada. Cada coeficiente mide el impacto de una variable manteniendo las otras constantes.

Multicolinealidad

Variables correlacionadas → coeficientes inestables


Overfitting

Demasiadas variables → memoriza ruido

Ejemplo: Precio de Casa

m², cantidad de habitaciones, ubicación



Regresión Logística



Regresión logística

Aunque se llama "regresión", se usa para **clasificación binaria**. Convierte una combinación lineal en una probabilidad entre 0 y 1.


$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$



Regresión logística

Aunque se llama "regresión", se usa para **clasificación binaria**. Convierte una combinación lineal en una probabilidad entre 0 y 1.

$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$




Interpretación

Salida entre 0 y 1 representa probabilidad

Ejemplo: Churn

Entrada: uso, edad, gasto. Salida: probabilidad de abandono

Métricas de clasificación



Métricas de clasificación

La matriz de confusión es la base de todas las métricas. Permite entender el tipo de errores y la distribución de aciertos.

VALORES PREDICCIÓN	Verdaderos positivos	Falsos Positivos
	Falsos Negativos	Verdaderos Negativos
VALORES REALES		

Métricas de clasificación

La matriz de confusión es la base de todas las métricas. Permite entender el tipo de errores y la distribución de aciertos.

VALORES PREDICCIÓN	VALORES REALES	
	Verdaderos positivos	Falsos Positivos
VALORES REALES	Falsos Negativos	Verdaderos Negativos



Métricas de clasificación



Accuracy

$$\frac{TP + TN}{Total}$$

Proporción de aciertos.

✗ Mala en datasets desbalanceados



Recall

$$\frac{TP}{TP + FN}$$

"De los positivos reales, cuántos detecté".

Importante cuando falsos negativos son costosos (ej: enfermedades)



Precision

$$\frac{TP}{TP + FP}$$

"De los que predije positivos, cuántos acerté".

Importante cuando falsos positivos son costosos (ej: fraude)




F1 Score

$$2 \frac{Precision \cdot Recall}{Precision + Recall}$$

Balance entre precision y recall

❏ No existe una métrica "mejor", depende del problema.

Métricas de regresión



Métricas de regresión



MSE

Penaliza errores grandes

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



RMSE

Misma unidad que la variable objetivo

$$\sqrt{MSE}$$



MAE

Más robusto a outliers

$$\frac{1}{n} \sum |y - \hat{y}|$$



R²

Varianza explicada.


1 → modelo perfecto.

0 → no mejora sobre la media.

Puede ser negativo (modelo muy malo)

$$1 - \frac{SS_{res}}{SS_{tot}}$$


Resumen



Resumen de la clase

- Qué es entrenar un modelo supervisado
- Función de costo
- Algoritmos:
 - Regresión lineal simple y múltiple
 - Regresión logística
- Métricas de clasificación.
- Métricas de regresión.

¿Consultas?



¡Muchas gracias!

