



MACHINE LEARNING CLASIFICACIÓN Y REGRESIÓN



Aprendizaje no supervisado

Módulo 4


Unidad 1: Análisis de clústers



Unidad 1

- Variables de escala
- Variables binarias
- Métodos de partición
- Clustering
- Algoritmos de clustering
- Métricas de clustering

Aprendizaje no supervisado



Aprendizaje no supervisado

Una rama del machine learning donde los algoritmos trabajan con datos **sin etiquetas ni variable objetivo**.

El objetivo es descubrir patrones ocultos, estructuras internas y agrupamientos presentes en los datos.

Aprendizaje Supervisado

¿Este cliente comprará?

¿Este correo es spam?


¿Cuál será el precio?

Aprendizaje No Supervisado


¿Qué tipos de clientes existen?

¿Qué observaciones se parecen?

¿Existen anomalías?



Tipos de variables



Variables de Escala o Intervalo

Son variables numéricas cuyos valores pueden **ordenarse, compararse y medirse**.

Estas variables permiten operaciones matemáticas como suma, resta, promedios, desvío estándar y distancias.

Característica Fundamental: el valor cero en estas escalas es un punto más en la escala, no representa la ausencia total de la magnitud que se está midiendo.

Ejemplos

- Temperatura
- Edad
- Ingresos
- Altura
- Peso
- Ventas

¿Por qué importan?

La mayoría de algoritmos de clusterización calculan **distancias matemáticas** entre observaciones.

Las variables de escala son esenciales para que esos cálculos tengan sentido.

Escalas de Medición

En estadística existen distintos tipos de escalas que determinan qué operaciones son válidas sobre los datos.

1

Nominal

Categorías sin orden. Ej: País, Color.

No tiene sentido comparar magnitud: "azul no es más grande que rojo".

2

Ordinal

Existe orden entre categorías (Bajo, Medio, Alto), pero sin distancia matemática exacta.

3

Intervalo

Diferencias interpretables, pero sin cero absoluto.

Ej: temperatura en °C. 0°C no significa ausencia de temperatura.

4

Razón

Posee todas las propiedades anteriores más cero absoluto.

Ej: Peso. "40 kg es el doble de 20 kg." "0 kg significa ausencia de peso"

Variables de Escala o Intervalo

¿Por qué nos importa tanto?

Mejora directa del rendimiento del modelo:

- Algoritmos como SVM, Redes Neuronales y PCA requieren que los datos estén escalados para converger correctamente y funcionar de manera óptima.
- Mejora la velocidad y la estabilidad del entrenamiento.

Análisis Gráfico Significativo:

- Facilita la creación de gráficos como scatter plots (gráficos de dispersión) para visualizar la relación entre dos variables numéricas, o mapas de calor para visualizar la correlación entre múltiples variables.

Variables binarias

Las variables binarias solo pueden tomar **dos valores posibles**:

0/1, Sí/No, Verdadero/Falso.

Son muy comunes en datos de negocio.

Ejemplos

- Compra realizada: Sí/No
- Cliente premium: Sí/No
- Tiene deuda: Sí/No

Problemas Frecuentes

- **Sparsity:** matrices muy dispersas
- **Alta dimensionalidad**
- **Similitudes artificiales**

No pueden tratarse igual que variables numéricas continuas.

Variables binarias

Las variables binarias **no solo son salidas, también pueden ser entradas (X)** para un modelo.


Ejemplos como Features:

- **es_fin_de_semana:** -> Para predecir ventas.
- **tiene_descuento:** -> Para predecir si se añadirá al carrito.
- **es_nuevo_usuario:** -> Para predecir la interacción.

Ingeniería de Características (Feature Engineering):

- A menudo creamos nuevas variables binarias a partir de otras variables para ayudar al modelo.
- Por ejemplo, a partir de la variable "edad", podemos crear una variable binaria `es_mayor_de_65`.

Métodos de partición



Métodos de partición

Los métodos de partición dividen un dataset en subconjuntos.

Si evaluamos un modelo sobre los mismos datos con los que fue entrenado, puede simplemente haber *memorizado* los datos — no aprendido patrones generales.



Este problema se conoce como **overfitting**: el modelo funciona muy bien en datos conocidos pero falla con datos nuevos.



Entrenamiento

El modelo aprende los patrones a partir de este subconjunto de datos.



Evaluación

Se mide el rendimiento real del modelo sobre datos nunca vistos.




Generalización

El objetivo final: que el modelo funcione bien con datos nuevos del mundo real.

Holdout: División Simple

El método Holdout divide el dataset **una única vez** en entrenamiento y prueba. Divisiones típicas: 70/30 o 80/20.



✓ Ventajas


- Simple y rápido
- Bajo costo computacional

✗ Desventajas

- Alta dependencia de la división
- Resultados inestables
- Posible sesgo si la muestra no es representativa

KFold Cross Validation

El dataset se divide en **K particiones del mismo tamaño**. Cada fold se utiliza una vez como conjunto de prueba mientras los restantes sirven para entrenamiento. Al final se promedian los resultados de todas las iteraciones.



✓ Ventajas

- Evaluación más robusta
- Reduce dependencia del azar
- Mejor aprovechamiento de datos

✗ Desventajas

- Mayor costo computacional
- Entrenamiento repetido múltiples veces

Leave-P-Out (LPO)

 **Idea principal:** LPO es la técnica de validación cruzada más **rigurosa y exhaustiva** posible.

En LPO se dejan **P observaciones fuera** como conjunto de prueba y el resto se usa para entrenamiento. El proceso se repite para **todas las combinaciones posibles**.

✓ Ventajas

- Máximo aprovechamiento de datos
- Muy útil en datasets pequeños

✗ Desventajas

- Extremadamente costoso computacionalmente
- Poco práctico en datasets grandes

Leave-P-Out (LPO)

¿Cómo Funciona Paso a Paso?

1. **Se elige un valor para p** (el tamaño del conjunto de prueba).
2. **El algoritmo crea una primera partición:** toma p muestras para la prueba y el resto $(N-p)$ para el entrenamiento.
3. **Entrena el modelo y lo evalúa.** Guarda el resultado.
4. **Repite** el proceso para la siguiente combinación única de p muestras.
5. **Continúa** hasta que se han probado TODAS las combinaciones posibles.
6. El rendimiento final es el **promedio de todos los resultados**.

Leave-P-Out (LPO)


Leave-One-Out (LOO)

Definición: Leave-One-Out (LOO) es simplemente un caso de LPO donde $p=1$.

¿Cómo Funciona?

- Se toma una única muestra del dataset como conjunto de prueba.
- Se entrena el modelo con todas las demás $N-1$ muestras.
- Se evalúa el modelo con la única muestra de prueba.
- Se repite este proceso N veces, una vez por cada muestra en el dataset.

Clusterización



Clusterización

La clusterización agrupa observaciones similares maximizando la **similitud interna** y la **separación entre grupos**.

Los grupos no se definen manualmente: el algoritmo los detecta automáticamente.



Clientes jóvenes
Compran tecnología
frecuentemente.



Clientes adultos
Prefieren productos para
el hogar.



Alto gasto
Clientes de alto valor
económico.



Ocasionales
Compran
esporádicamente.

Similitud y distancia

La clusterización depende completamente del concepto de **similitud**: observaciones similares deben quedar cercanas; diferentes, lejanas.

Las tres métricas principales son:

Distancia Euclidiana

Distancia en línea recta. La más utilizada en K-Means.

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Distancia Manhattan

Sigue ejes horizontales y verticales.
Reduce el impacto de outliers.


$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

Distancia Minkowski

Generaliza las anteriores: **p=1** → Manhattan; **p=2** → Euclidiana.

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}$$


Algoritmos



K-Means

El algoritmo K-Means busca dividir los datos en **K grupos o "clusters"**, donde cada grupo posee un centroide que representa su centro. El objetivo es minimizar la distancia entre los puntos de datos y su centroide asignado.

Funcionamiento paso a paso



Problemas de K-Means

Sensibilidad a Outliers


Valores extremos pueden mover significativamente los centroides, distorsionando los clusters.

Sensibilidad a la Escala

Si las variables no están escaladas, el algoritmo puede producir clusters incorrectos al dar más peso a variables con rangos mayores.

Necesidad de definir K

El algoritmo requiere indicar previamente la cantidad de clusters, lo cual no siempre es conocido o fácil de determinar. Este es uno de sus principales desafíos.



Clusterización jerárquica

Este método construye una jerarquía de clusters, revelando las relaciones entre los grupos sin necesidad de definir el número 'K' de antemano. Se divide en dos enfoques principales:

Aglomerativo (Bottom-up)

Cada punto inicia como un cluster individual y se van fusionando los grupos más cercanos hasta formar uno grande.

Divisivo (Top-down)

Todos los puntos comienzan en un gran cluster que se divide recursivamente en subgrupos cada vez más pequeños.


Dendrograma

Es una representación visual clave de las fusiones o divisiones de clusters.


Permite:

- Identificar el número óptimo de grupos.
- Visualizar la estructura jerárquica y similitudes.
- Elegir el "corte" para definir los clusters finales.

Clusterización jerárquica



Métricas



Métricas para clusterización

Una vez que se han formado los clusters, es crucial evaluar su calidad. Estas métricas nos ayudan a entender qué tan bien se agrupan los datos y cómo se diferencian los clusters entre sí.

Inertia

Mide la suma de las distancias al cuadrado de cada punto a su centroide asignado. Una **menor inercia** indica clusters más compactos y, generalmente, mejor definidos.

$$\text{Inertia} = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

Silhouette Score


Evalúa tanto la cohesión interna de los puntos dentro de su cluster como su separación de otros clusters. Un valor cercano a **+1** indica un buen clustering, mientras que un valor cercano a **0** sugiere clusters superpuestos o mezclados, y valores **negativos** indican una asignación incorrecta.

$$s = \frac{b - a}{\max(a, b)}$$


Método del Codo (Elbow Method)

Es una técnica heurística para determinar el número óptimo de clusters (K). Se ejecuta K-Means para un rango de valores de K y se grafica la inercia. El punto donde la reducción de la inercia comienza a disminuir drásticamente (formando un "codo") es a menudo el valor óptimo de K.

Métricas para clusterización




Resumen



Resumen de la clase

- Tipos de variables
- Métodos de partición
- Clustering
- Algoritmos de clustering
- Métricas de clustering

¿Consultas?



¡Muchas gracias!

