



MACHINE LEARNING CLASIFICACIÓN Y REGRESIÓN



Aprendizaje no supervisado

Módulo 4


Unidad 2: Reducción de dimensionalidad




Unidad 2

- Reducción de dimensionalidad
 - o Análisis factorial
 - o Análisis de componentes principales
 - o Escala multidimensional
- Mapeo de características principales

Reducción de dimensionalidad





Reducción de Dimensionalidad

Una técnica fundamental en Machine Learning que permite **disminuir la cantidad de variables** de un dataset conservando la mayor información relevante posible.

En esencia: transformar un problema complejo con muchas variables en otro equivalente, más simple y manejable.

La maldición de la dimensionalidad

Cada variable o característica de un dataset representa una **dimensión**.

Cuando aumentan las dimensiones, los datos se vuelven más dispersos, las distancias pierden significado y los modelos requieren muchos más datos para entrenar correctamente.

La visualización humana también se vuelve imposible más allá de 3 dimensiones.

Selección de Variables

- Elimina variables existentes
- Conserva las variables originales
- Ejemplo: eliminar columnas irrelevantes

Reducción de Dimensionalidad

- Crea nuevas variables combinadas
- Combina información de múltiples variables
- Ejemplo: PCA, Análisis Factorial

Objetivos de la reducción de dimensionalidad

1

Simplificar datos

Reducir la complejidad matemática y computacional. Ejemplo: pasar de 500 variables a solo 10.

2

Reducir ruido

Eliminar variables con errores, variaciones irrelevantes o información inútil para mejorar los resultados.

3

Facilitar visualización

Los humanos solo podemos visualizar 2 o 3 dimensiones. Reducir permite interpretar espacios complejos.

4

Mejorar rendimiento


Menos variables implica menos cálculos, menor uso de memoria y entrenamiento más rápido.

5

Mejorar generalización

Demasiadas variables producen *overfitting*. Reducir dimensiones ayuda al modelo a generalizar mejor.

Análisis factorial



Análisis factorial


Es una técnica estadística de reducción de dimensionalidad que identifica **variables ocultas llamadas factores**.

Estos factores no se observan directamente, pero explican el comportamiento de múltiples variables observadas.

Muchas variables observadas dependen de una menor cantidad de factores subyacentes no observables.

Ejemplo Encuesta educativa: Con 6 variables (nota matemática, física, química, comprensión lectora, redacción, vocabulario), el análisis factorial puede descubrir que solo existen **dos capacidades generales**: habilidad científica y habilidad verbal.

Si varias variables están muy correlacionadas, probablemente exista un **factor común** detrás. El objetivo es resumir un conjunto grande de variables en una menor cantidad de factores latentes.



¿Qué es un factor?

Un factor es una **variable no observable directamente** que influye sobre varias variables observadas. Se infiere matemáticamente a partir de los datos.

Factores Ocultos

- **Inteligencia verbal** → vocabulario, lectura, redacción
- **Inteligencia matemática** → álgebra, física, estadística



Criterio de extracción: Se conservan los factores con **eigenvalue (autovalor) mayor a 1**, ya que representan una cantidad significativa de varianza explicada.

Modelo Matemático

Cada variable observada se expresa como combinación de factores comunes más un componente de error:

$$X_i = a_{i1}F_1 + a_{i2}F_2 + \dots + a_{im}F_m + e_i$$

Donde X_i es la variable observada, F_j son los factores, a_{ij} son las **cargas factoriales** (indican cuánto influye cada factor) y e_i es el error.

FA: Ventajas y desventajas

✓ Ventajas

- Encuentra **estructuras ocultas** en los datos
- Facilita la **interpretación** de relaciones entre variables
- Elimina **redundancia** informativa
- Ayuda a construir **indicadores compuestos**

⚠ Desventajas

- **Interpretación subjetiva:** nombrar factores depende del analista
- **Sensibilidad a correlaciones:** si las variables no están correlacionadas, el método pierde sentido
- **Requiere suficientes datos:** con pocas observaciones puede producir resultados inestables

📋 Caso: Encuesta de Satisfacción Laboral

Variables medidas: Salario, Relación con jefes, Balance vida/trabajo, Oportunidades de crecimiento, Estrés, Motivación.

Factor Descubierto

Variables Asociadas

Bienestar laboral

Motivación, balance, estrés


Desarrollo profesional

Salario, crecimiento

Clima organizacional

Relación con jefes

Análisis de componentes principales (PCA)



Análisis de componentes principales (PCA)

Técnica que transforma un conjunto grande de variables en un conjunto menor de nuevas variables llamadas **componentes principales**.

Estas nuevas variables son combinaciones lineales, no están correlacionadas entre sí y conservan la mayor cantidad posible de varianza.

Combinaciones Lineales

Cada componente es una mezcla ponderada de todas las variables originales.

No Correlacionados

Los componentes son independientes entre sí, eliminando redundancia.

Maximizan Varianza

El primer componente captura la mayor variabilidad posible de los datos.

Compactan Información

Permite representar datos complejos con menos dimensiones sin perder información clave.

Los componentes principales

Cada componente principal es una **nueva variable matemática** creada como combinación lineal de las originales.

PCA identifica las **direcciones principales** (eigenvectors) y cuantifica cuánta información explica cada una (eigenvalues).

Fórmula del Componente Principal

$$CP_1 = a_1X_1 + a_2X_2 + a_3X_3 + \dots$$

Donde X_i son las variables originales y a_i son los pesos asignados por el algoritmo.

Eigenvectors y Eigenvalues

- **Eigenvectors:** representan las direcciones principales en el espacio de datos
- **Eigenvalues:** indican cuánta información explica cada dirección

Varianza Explicada — Ejemplo

Componente	Varianza
PC1	55%
PC2	25%
PC3	10%

Con PC1 + PC2 se conserva el **80% de la información** original.

Ejemplo: Datos Físicos

Altura, peso y masa muscular están correlacionados. PCA los resume en un solo componente: "**Tamaño corporal general**".

PCA: ventajas y desventajas

✓ Ventajas

→ Reduce dimensionalidad

Simplifica datasets con cientos de variables.

→ Elimina redundancia

Combina variables correlacionadas en un solo componente.

→ Facilita visualización

Permite proyectar datos en 2D o 3D interpretables.

→ Mejora tiempos de entrenamiento

Menos variables = modelos más rápidos y eficientes.

⚠ Desventajas

Pérdida de interpretabilidad

Los componentes son combinaciones matemáticas abstractas, difíciles de interpretar en términos del negocio o dominio.


Pérdida de información

Reducir demasiado puede deteriorar los resultados del modelo si se descartan componentes importantes.

Sensibilidad al escalado

Las variables deben estar normalizadas; de lo contrario, las de mayor escala dominarán los componentes.

Escala multidimensional



Escala multidimensional


Técnica de visualización y reducción de dimensionalidad que busca representar datos complejos en un espacio de bajas dimensiones (generalmente 2D o 3D), **manteniendo las distancias o similitudes relativas entre las observaciones originales.**

✓ Ventajas


- Excelente para la **visualización** de estructuras de datos.
- Preserva las **relaciones de distancia** y similitud entre puntos.
- Flexible respecto a las **métricas de distancia** utilizadas.
- Resultados **gráficamente intuitivos**, útiles para análisis exploratorio.

⚠ Limitaciones

- **Alto costo computacional:** puede ser lento con grandes datasets debido al cálculo de distancias por pares.
- **Sensibilidad al ruido:** datos ruidosos pueden distorsionar significativamente las distancias y los resultados.
- **Interpretación de ejes:** los ejes obtenidos no poseen un significado físico o conceptual claro.
- **Dependencia de la métrica:** el resultado final puede variar drásticamente según cómo se definan las distancias (Euclidiana, Manhattan, etc.).



Mapeo de características principales



Mapeo de características principales

Técnica avanzada de análisis de datos que fusiona principios del Análisis Factorial y el Análisis de Componentes Principales.

Su objetivo principal es representar datos complejos en un espacio de menor dimensión, **preservando al máximo las características más importantes** y facilitando la visualización de patrones y relaciones.

✓ Ventajas



Reduce dimensionalidad y visualiza: Simplifica datasets complejos y los hace más fáciles de interpretar visualmente.



No paramétrica: No asume una distribución específica de los datos, lo que la hace flexible para diversas estructuras de datos.



Análisis multivariante: Capaz de manejar y analizar varias variables simultáneamente, revelando interacciones complejas.



Desventajas

No predictivo

PCM está diseñado para el análisis y la visualización, no para predecir valores futuros o resultados específicos.


Posible pérdida de información

Al reducir la dimensionalidad, existe el riesgo inherente de perder información crucial si la reducción es excesiva o inadecuada.

Sensibilidad al ruido

La presencia de ruido o valores atípicos en los datos de entrada puede afectar significativamente la calidad y la interpretación del mapeo resultante.


Resumen



Resumen de la clase

- Análisis factorial
- Análisis de componentes principales
- Escala multidimensional
- Mapeo de características principales

¿Consultas?



¡Muchas gracias!

